




Aumento de Datos y Text Augmentation

Módulo 04_GenIA · Análisis y Visualización de Datos con Python

TRANSFORMA POCOS DATOS EN MUCHOS... ¡CON INTELIGENCIA!

Agenda del Módulo

01

¿Qué es el Data Augmentation?

Conceptos fundamentales y definición

02

Técnicas de Aumento

Imágenes y Text Augmentation

03

Overfitting vs Underfitting

Problemas que resuelve

04

Herramientas & Ecosistema

Python + Microsoft

05

Buenas Prácticas & Examen

Patrones, casos prácticos y recomendaciones

El Problema: Pocos Datos

Bajo rendimiento

Precisión baja y resultados poco confiables

Overfitting

El modelo memoriza en vez de aprender


Alto costo

Obtener más datos reales es caro y lento

Poca variedad

Escasa diversidad de escenarios de entrenamiento

 **La solución:** Data Augmentation = crear NUEVOS ejemplos a partir de los existentes, sin coste adicional de recolección.



¿Qué es el Data Augmentation?



Técnica que genera nuevas muestras de entrenamiento **modificando ligeramente los datos originales** sin alterar su información esencial.

Ejemplo: Una foto de un gato puede convertirse en muchas

- 🔄 Rotaciones: 15°, 30°, 45°
- ☀️ Cambios de brillo e iluminación
- 🔍 Zoom: acercar y alejar
- 🔄 Reflejo horizontal/vertical
- 🌧️ Añadir ruido aleatorio
- 🎨 Variaciones de color y saturación

Resultado: Todas siguen siendo fotos de un gato, ¡pero son imágenes distintas!

Analogía: Enseñar a Reconocer Perros

✗ Mal enfoque

Solo 3 fotos de perros sentados. El modelo no ve variedad y falla con cualquier imagen diferente.

✓ Buen enfoque

- Perros grandes y pequeños
- Sentados, corriendo, durmiendo
- Distintos colores y razas
- Diferentes condiciones de luz

🎯 **Más diversidad = mejor capacidad de reconocer patrones generales.** Eso es exactamente el Data Augmentation.

Técnicas de Aumento en Imágenes



Rotación

Gira la imagen (15° – 45°). Permite reconocer objetos desde cualquier ángulo.



Escalado / Zoom

Acerca o aleja la imagen. Reconoce objetos a distinta distancia.



Ruido

Agrega perturbaciones aleatorias. Tolera imágenes imperfectas del mundo real.



Flip / Volteo

Refleja horizontal o verticalmente. Amplía variedad de posiciones.



Brillo / Contraste

Modifica la iluminación. Hace el modelo robusto frente a distintas luces.



Color / Saturación

Varía tono y balance cromático. Introduce diversidad de condiciones visuales.



Overfitting vs Underfitting

🔥 Overfitting (Sobreajuste)

El modelo **memoriza** los datos de entrenamiento. Excelente rendimiento en entrenamiento, pero **pésimo con datos nuevos**.

Analogía: Estudiante que memoriza respuestas sin entender el concepto.

✅ Solución: **Data Augmentation + más datos diversos**

⚠️ Underfitting (Subajuste)

El modelo es demasiado simple y **no aprende los patrones**. Bajo rendimiento tanto en entrenamiento como en prueba.

Analogía: Estudiante que no estudia nada.

✅ Solución: **Modelo más complejo + más épocas**

📄 🎯 El Data Augmentation combate **principalmente el Overfitting**, aumentando la diversidad del conjunto de entrenamiento.

Beneficios del Data Augmentation



Más datos de entrenamiento

Incrementa artificialmente el tamaño del dataset sin costes adicionales de recolección.



Mejor generalización

El modelo aprende patrones generales en lugar de memorizar ejemplos concretos.



Menor costo

No necesitas recolectar ni etiquetar miles de datos nuevos desde cero.



Mayor robustez

El modelo se adapta mejor a variaciones del mundo real: luces, ángulos, ruido.

Aplicaciones Prácticas




Medicina

Aumenta imágenes médicas escasas (radiografías, resonancias, lesiones cutáneas) para mejorar el diagnóstico asistido por IA.



Vehículos Autónomos

Genera escenarios sintéticos: lluvia, niebla, noche, tráfico y accidentes. Entrena sin exponer personas a riesgos.



NLP & Chatbots

Enriquece datasets de texto para chatbots, análisis de sentimientos y traducción automática.

Text Augmentation: ¿Qué es?

Definición

Técnica de preprocesamiento que **crea nuevas versiones de un texto** sin modificar su significado principal. Amplía el vocabulario y las estructuras que el modelo comprende.

¿Por qué importa?

Una misma idea puede expresarse de muchas formas. Cuantas más formas conozca el modelo, mejor comprenderá textos reales.

"El perro está feliz"

Versión original

"El can está contento"

Sinónimos

"El canino luce alegre"

Paráfrasis

"El perro se encuentra feliz"

Retrotraducción

Técnicas de Text Augmentation



Reemplazo de Sinónimos

Sustituye palabras por equivalentes.
Usa WordNet o Word Embeddings contextuales.



Retrotraducción

Traduce a otro idioma y vuelve.
Genera paráfrasis naturales por diferencias gramaticales.



Inserción / Eliminación

Añade o elimina palabras de forma controlada. Modela variaciones e imperfecciones del texto real.

💡 **Tip:** Para Back Translation, prueba múltiples lenguas intermedias: Español → Francés → Alemán → Español.

Técnicas Modernas de Text Augmentation

Embeddings Semánticos

Usa Sentence Transformers y Word Embeddings para encontrar palabras/frases similares **por significado**, no solo por diccionario. Reemplazos mucho más inteligentes.

Sentence Shuffling

Cambia el orden de oraciones dentro de un documento. Obliga al modelo a entender el contexto completo, no solo la posición.

Modelos Generativos

Usa **Microsoft Copilot, GPT** y otros LLMs para generar paráfrasis, nuevos ejemplos y variaciones contextuales de alta calidad.



Riesgos del Aumento Excesivo

✗ **Más datos no siempre significa mejor modelo.** El exceso de transformaciones puede perjudicar el entrenamiento.

Ruido innecesario

Se introducen variaciones que no existen en el mundo real.

Pérdida de información

Se diluyen o destruyen los patrones originales del dataset.

Over-augmentation

El modelo aprende de ejemplos irreales que degradan su rendimiento.

📋 🍲 **Analogía culinaria:** Agregar demasiadas especias arruina la comida. **Regla de oro: Moderación + Validación continua del rendimiento.**

Data Augmentation vs Datos Sintéticos

Característica	Data Augmentation	Datos Sintéticos
¿Cómo?	Modifica datos existentes	Genera datos completamente nuevos
Base	Conserva info original	Aprende distribución estadística
Uso típico	Imágenes principalmente	Imágenes, texto, audio, tabulares
Complejidad	Implementación sencilla	Requiere GAN, VAE, Transformers
Ejemplo	Rotar una foto de un perro	Crear un perro que nunca existió

¿Cuándo usar cada uno?

Data Augmentation es el primer recurso: rápido, sencillo y efectivo para la mayoría de casos con imágenes y texto.

Datos Sintéticos entran en juego cuando el aumento no es suficiente, cuando los datos son tabulares o cuando se necesitan escenarios imposibles de capturar.

Ecosistema de Herramientas Python



OpenCV / Albumentations

Procesamiento y transformación de imágenes: rotar, flip, brillo. Albumentations está **especializada** en visión artificial.



Keras / Torchvision

ImageDataGenerator de Keras aplica aumento automático durante el entrenamiento. Torchvision para modelos PyTorch.



SDV (Synthetic Data Vault)

Genera datos sintéticos **tabulares**: Excel, CSV, DataFrames. Ideal para datasets estructurados.



NLTK / spaCy / HuggingFace

NLP completo: sinónimos con WordNet, Sentence Transformers y modelos generativos para Text Augmentation.

Ecosistema Microsoft

Azure Machine Learning

Plataforma ML que integra Data Augmentation en pipelines de entrenamiento completos.

Azure AI Foundry

Crea apps de IA Generativa e integra modelos generativos y datos sintéticos.

Azure OpenAI Service

Modelos GPT en Azure para generar texto sintético y datos de entrenamiento NLP.

Microsoft Copilot

Genera nuevas oraciones **contextualmente relevantes** para Text Augmentation de forma directa.



Limitaciones y Buenas Prácticas

✗ Limitaciones a conocer

- No reemplaza datos reales de buena calidad
- Transformaciones excesivas generan ejemplos irreales
- No resuelve datos mal etiquetados
- Sinónimos incorrectos cambian el significado
- Back Translation depende de la calidad del traductor

✓ Buenas prácticas

- Aplica solo transformaciones realistas
- Conserva siempre la información esencial
- Combina varias técnicas de aumento
- Valida el impacto en la precisión del modelo
- En imágenes médicas: mantén coherencia de etiquetas
- Documenta cómo fueron generados los datos

📌 **Regla de oro:** Moderación + Validación continua. Menos puede ser más.

Casos Prácticos de Examen

1

Flores – Dataset pequeño

Solución: Aumento de datos → Genera nuevas imágenes con rotaciones, brillo y flip.

2

Defectos raros en fabricación

Solución: Datos sintéticos → Crea ejemplos artificiales de defectos poco frecuentes.

3

Chatbot con variaciones gramaticales

Solución: Inserción/Eliminación aleatoria → Hace el modelo resistente a imperfecciones.

4

Aeronaves vistas solo de lado

Solución: Rotación → Muestra aviones desde distintos ángulos durante el entrenamiento.

Patrón Secreto para el Examen

Cuando el enunciado mencione ciertos conceptos clave, **elige siempre el modelo correspondiente:**

Palabras clave en el enunciado	Elige	¿Por qué?
Realismo, imágenes, audio, video, ultra-real	GAN	2 redes compiten = máxima calidad visual
Privacidad, datos sensibles, espacio latente, tabulares	VAE	Encoder + Decoder = control y privacidad
Texto, lenguaje, atención, contexto largo	Transformers	GPT, BERT = arquitectura estrella NLP
Generación secuencial, paso a paso	Autorregresivo	PixelCNN, series temporales
Probabilidades exactas, transformaciones invertibles	Flow-Based	RealNVP = reversibilidad garantizada

10 Ideas Clave para Recordar

1 Data Augmentation = modificar datos existentes

Sin cambiar su significado esencial ni añadir etiquetas nuevas.

2 Combate principalmente el Overfitting

Más variedad = mejor generalización a datos nunca vistos.

3 Técnicas imágenes

Rotación, flip, brillo, ruido, crop, zoom y color.

4 Text Augmentation

Sinónimos, Back Translation, Inserción/Eliminación y Modelos Generativos.

5 Data Augmentation ≠ Datos Sintéticos

Modifica lo que existe vs. crea desde cero con GAN o VAE.



 **Clave del éxito:** Moderación + Validación = modelos robustos, eficientes y bien generalizados.