

# Datos Sintéticos en Machine Learning

Cómo superar la escasez de datos y el desequilibrio de clases de forma ética y eficiente.

EQUIPO DE CIENCIA DE DATOS

APRENDIZAJE SUPERVISADO · LECTURAS 20–24





# ¿Qué son los Datos Sintéticos?

Datos generados artificialmente mediante algoritmos y modelos matemáticos que **imitan con precisión** las propiedades estadísticas, relaciones y patrones de los datos reales — sin copiar ningún registro individual.

- ❏ Analogía: en lugar de fotografiar miles de aves reales para entrenar un clasificador, creamos modelos 3D hiperrealistas de esas aves. Misma estructura lógica, cero exposición de datos privados.

# Los 4 Grandes Problemas que Resuelven



## Escasez de Datos

Generan conjuntos de entrenamiento suficientemente grandes cuando recolectar datos reales es difícil o costoso.



## Privacidad

Protegen información confidencial en sectores regulados como medicina y finanzas.



## Desequilibrio de Clases

Compensan la escasez de ejemplos en clases minoritarias: fraude, enfermedades raras, anomalías.



## Datos Incompletos

Permiten el *data augmentation* introduciendo variaciones sintéticas para modelos más resilientes.



# Medicina, Conducción Autónoma y Finanzas

## Atención Médica

Historias clínicas sintéticas para entrenar modelos de detección temprana de diabetes sin exponer datos reales de pacientes.

## Vehículos Autónomos

Simulación de escenarios peligrosos —tormentas, cierres bruscos de vía— sin arriesgar vidas humanas durante las pruebas.

## Detección de Fraude

Aumento sintético de transacciones fraudulentas para que los clasificadores reconozcan patrones delictivos nuevos y poco frecuentes.



# Retail, Robótica, Agricultura y Entretenimiento



## Comercio Minorista

Perfiles de compra ficticios para probar estrategias de marketing sin ser invasivos con clientes reales.



## Robótica

Entrenamiento en simuladores físicos para tareas industriales complejas sin riesgo de daños materiales.



## Agricultura

Imágenes sintéticas de cultivos con plagas o deficiencias nutricionales para modelos de detección automatizada.



## Entretenimiento

Contenido 3D personalizado y entornos de realidad virtual generados sintéticamente.

# ¿Cómo se Generan? La Biblioteca SDV

## Synthetic Data Vault en Python

SDV modela la estructura de datos tabulares reales y genera datos sintéticos estadísticamente coherentes en cinco pasos claros.

- SDV detecta automáticamente tipos de columna: numérico, categórico y booleano, antes de entrenar cualquier sintetizador.



# Enfoques de Generación en SDV

SDV ofrece tres sintetizadores con diferentes compromisos entre velocidad y capacidad para capturar patrones complejos.

1

## GaussianCopula

Estadística clásica. Aprende distribuciones y correlaciones mediante funciones de cópula.

**Rápido y eficiente**; ideal como punto de partida.

2

## CTGAN

Redes Generativas Adversarias (Deep Learning). Dos redes en competencia modelan patrones no lineales altamente complejos.

3

## TVAE

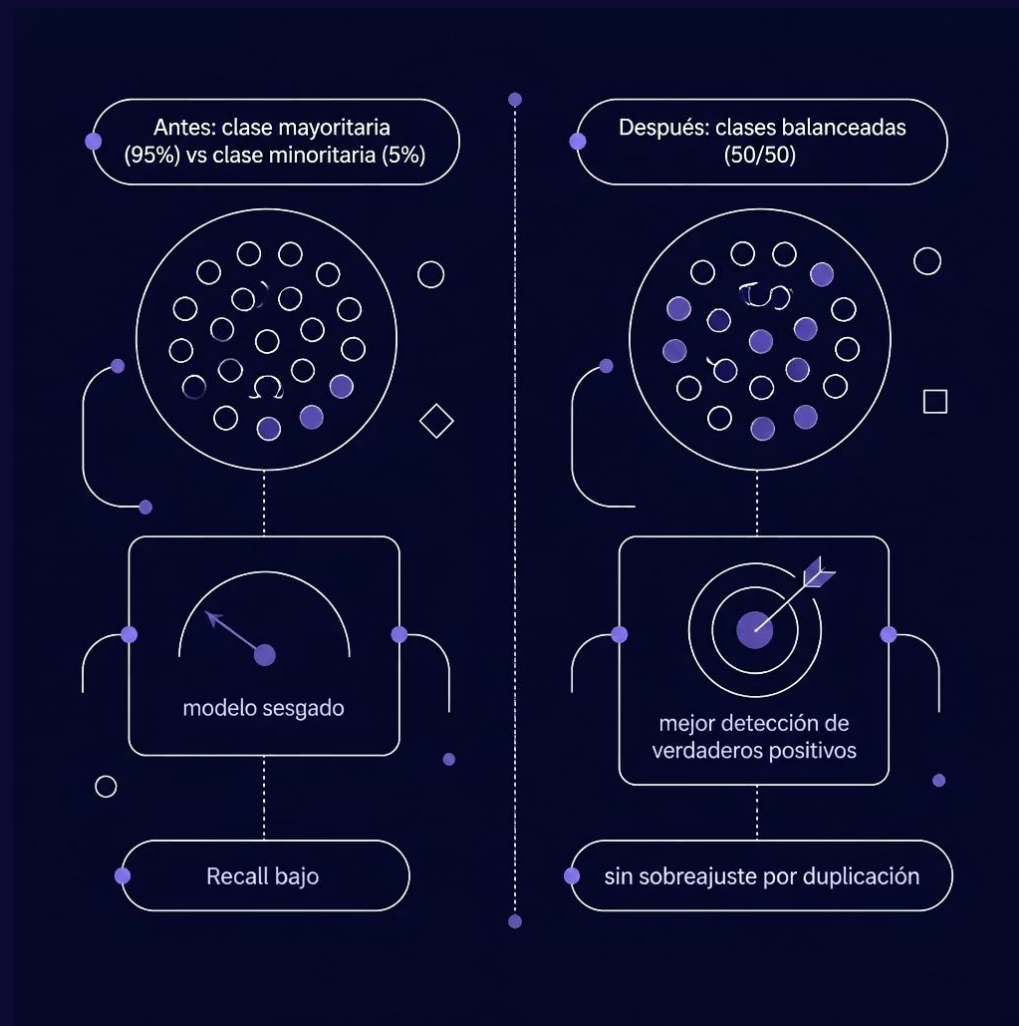
Autoencoders Variacionales. Codifica datos en un espacio latente y los reconstruye con variaciones realistas y diversas.

# Desequilibrio de Clases y SMOTE

Un modelo entrenado con clases muy desiguales —95% sanos, 5% enfermos— se sesga hacia la mayoría: alta precisión global pero **Recall muy bajo** en la clase crítica.

## ¿Cómo opera SMOTE?

1. Selecciona ejemplos de la clase minoritaria.
2. Traza líneas hacia sus  $k$  vecinos más cercanos.
3. Crea nuevos puntos sintéticos **a lo largo** de esas líneas.
4. Logra una distribución balanceada (ej. 50/50) sin duplicar filas.







# Entrenamiento vs. Pruebas con Datos Sintéticos



## Fase de Entrenamiento

Aumentar el tamaño y la diversidad del dataset para evitar el *overfitting* cuando las muestras reales disponibles son escasas.



## Fase de Pruebas (Robustez)

Generar casos extremos y **ataques adversarios simulados** para detectar vulnerabilidades del modelo antes de llevarlo a producción.

# Privacidad y Uso Responsable

## Anonimización



Eliminación o enmascaramiento de nombres, IDs y direcciones antes de entrenar los generadores.

## Privacidad Diferencial



Inyecta ruido matemático controlado para imposibilitar la reconstrucción de registros individuales reales.



📌 **Regla de Oro:** Los datos sintéticos son un *complemento*, no un reemplazo. La validación final de modelos clínicos o financieros siempre exige datos del mundo real.

# Consideraciones Éticas Críticas

## 1 Validación Estadística

Comprobar que el comportamiento estadístico de los datos sintéticos imite fielmente el de los datos reales de referencia.

## 2 Mitigación de Sesgos

Garantizar que los datos sintéticos no amplifiquen sesgos históricos de género, etnia o nivel socioeconómico presentes en el origen.

## 3 Validación en el Mundo Real

Realizar pruebas clínicas o de campo con **poblaciones diversas reales** antes de implantar cualquier modelo en producción.

