

Machine Learning con Python

Guía Completa del Curso

Este documento consolida el contenido de todos los módulos del curso, organizado de forma didáctica y visual. Todo el contenido, ejemplos y casos de uso provienen exclusivamente de los videos del curso.

```
(boolean)  
boolean = True  
data : ", data_boolean  
ta khusus (complex)  
ex = complex(5,6)  
: ", data_complex, t  
anakan tipe data dari  
port c_double  
c_double(10, 5)  
data
```

Cómo está organizada esta guía

Esta presentación está diseñada para acompañar tu aprendizaje con un enfoque visual y progresivo.

01

Conceptos fundamentales

¿Qué es ML y cómo aprende un modelo?

02

Tipos y aplicaciones

Supervisado, no supervisado y por refuerzo

03

Flujo de un proyecto


Datos, entrenamiento, evaluación y mejora

04

Métricas y código

Herramientas para medir y comparar modelos

❏ Todo el contenido proviene exclusivamente de los videos del curso. No se agregan algoritmos ni conceptos avanzados no mencionados.



¿Qué es Machine Learning?

Machine Learning (Aprendizaje Automático) es una rama de la **Inteligencia Artificial** que permite a las computadoras aprender a partir de datos, sin necesidad de ser programadas explícitamente para cada situación.

Programación Tradicional

El programador escribe miles de reglas manualmente para cada caso posible.

Machine Learning

El sistema **descubre patrones automáticamente** a partir de los datos. Las reglas emergen solas.

¿Cómo aprende un algoritmo?

El curso utiliza una analogía muy intuitiva para explicar el proceso de aprendizaje automático.




1. Se muestran muchas imágenes

Cada imagen tiene una etiqueta que identifica el animal.



2. Se identifican patrones

El niño —o el algoritmo— comienza a asociar características con etiquetas.



3. Reconoce casos nuevos

Finalmente puede identificar animales que nunca había visto antes.

¿Cómo aprende un modelo?

El entrenamiento es el corazón del Machine Learning. El modelo analiza ejemplos, identifica relaciones y ajusta sus parámetros de forma iterativa.



Un principio clave del curso: **cuantos más datos tenga el modelo, mejores serán normalmente sus predicciones**. Durante el entrenamiento, el algoritmo ajusta sus parámetros continuamente para minimizar el error.

Aprendizaje Supervisado

Características clave

- Datos **etiquetados**
- Se conoce la respuesta correcta
- Aprende mediante ejemplos explícitos

Ejemplos del curso

- Clasificación de imágenes
- Detección de spam en correos
- Detección de fraude bancario
- Predicción de precios

Aprendizaje No Supervisado

Características clave

- Datos **sin etiquetas**
- Busca patrones ocultos
- Agrupa elementos similares

Ejemplos del curso

- Segmentación de clientes
- Detección de anomalías
- Reducción de dimensionalidad



Aprendizaje por Refuerzo

¿Cómo funciona?

Agente

Toma decisiones en el entorno

Recompensa

Recibe feedback positivo o negativo

Aprendizaje

Mejora mediante prueba y error

Ejemplos del curso

- Vehículos autónomos
- Robots industriales
- Juegos como el ajedrez



APLICACIONES

Netflix: Recomendación Personalizada

Netflix utiliza Machine Learning para analizar el historial de visualización de cada usuario y **recomendar películas y series personalizadas**.

El algoritmo aprende qué tipo de contenido prefiere cada persona y mejora sus sugerencias con cada interacción, aumentando el tiempo de permanencia en la plataforma.

Bancos: Detección de Fraude



¿Cómo lo hace?

Los bancos analizan **millones de transacciones** en tiempo real. Los modelos de ML supervisado identifican patrones inusuales que podrían indicar actividad fraudulenta, bloqueando operaciones sospechosas antes de que causen daño.

- Más rápido que los sistemas basados en reglas
- Mayor precisión en la detección
- Se adapta a nuevos patrones de fraude



APLICACIONES

Comercio Electrónico: Recomendación de Productos

Las plataformas de e-commerce utilizan el **historial de compras**, el historial de navegación y los datos demográficos del usuario para recomendar productos personalizados.

El resultado es una experiencia de compra más relevante que **incrementa las ventas y la satisfacción del cliente**.

Medicina: Diagnóstico Asistido por ML



Análisis de radiografías

Los modelos identifican anomalías en imágenes médicas con alta precisión.



Resonancias magnéticas

Detecta patrones que pueden indicar enfermedades neurológicas.



Detección temprana

Identifica enfermedades en etapas iniciales, cuando el tratamiento es más efectivo.

Asistentes Virtuales



Siri y Alexa

Estos asistentes virtuales utilizan Machine Learning para **entender el lenguaje natural**, interpretar comandos de voz y mejorar sus respuestas con el tiempo.

Aprenden de cada interacción para ofrecer resultados cada vez más precisos y personalizados.



Ambos son ejemplos mencionados explícitamente en el curso.

Traducción Automática

Los modelos de Machine Learning han revolucionado la traducción automática, **eliminando barreras idiomáticas** a escala global.

En lugar de traducir palabra por palabra, aprenden el contexto y el significado completo de las frases, produciendo traducciones mucho más naturales y precisas que los sistemas anteriores basados en reglas.



Redes Sociales: Contenido Personalizado

¿Qué hacen?

Las redes sociales utilizan ML para seleccionar **automáticamente** qué contenido mostrar a cada usuario en su feed.

¿Cómo lo logran?

- Analizan el comportamiento del usuario
- Identifican preferencias de contenido
- Priorizan publicaciones relevantes
- Aprenden de cada interacción (likes, tiempo de visualización)




APLICACIONES

Vehículos Autónomos

Los autos autónomos son uno de los ejemplos más completos del curso porque **combinan los tres tipos de Machine Learning** simultáneamente: aprendizaje supervisado para reconocer objetos y señales, no supervisado para detectar nuevos escenarios, y por refuerzo para entrenar las decisiones de conducción.

Flujo General de un Proyecto de ML

Todo proyecto de Machine Learning sigue un ciclo iterativo. Comprender este flujo es fundamental para trabajar con modelos reales.



El proceso no es lineal: los resultados de la **evaluación** alimentan la **mejora continua** del modelo, volviendo a las etapas anteriores hasta obtener el desempeño deseado.

El Dataset del Curso: Iris



¿Qué contiene?

El **Iris Dataset** es el conjunto de datos utilizado en el curso. Incluye tres especies de flores con cuatro características medidas para cada muestra.

Longitud del
sépal

Ancho del sépal


Longitud del pétalo

Ancho del pétalo

Objetivo: predecir la especie de la flor a partir de estas medidas.

División Train / Test

Antes de entrenar cualquier modelo, los datos deben dividirse en dos conjuntos: uno para entrenar y otro para evaluar el desempeño con datos que el modelo nunca ha visto.



```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split( X, y, test_size=0.30, random_state=42 )
```

Regresión Logística

¿Qué hace?

Busca una **frontera lineal** en el espacio de datos para separar las distintas clases entre sí.

Características

- Modelo de clasificación (no de regresión)
- Simple e interpretable
- Funciona bien cuando los datos son separables linealmente
- Punto de partida ideal para clasificación

```
from sklearn.linear_model import LogisticRegression
```

```
log_reg = LogisticRegression()
```

```
log_reg.fit(X_train, y_train)
```

A close-up, shallow depth-of-field photograph of a person's hand and arm, wearing a dark blue short-sleeved shirt, drawing a diagram on a white surface. The hand is holding a blue marker and is in the process of drawing a line that connects a circle on the left to a triangle on the right. The background is a solid dark blue color.

MODELOS

Árbol de Decisión

un **Árbol de Decisión** construye una estructura en forma de árbol basada en preguntas sucesivas sobre los datos.

En cada nodo, el modelo realiza una pregunta sobre una característica y divide los datos según la respuesta, hasta llegar a una **predicción final en las hojas del árbol**.

```
from sklearn.tree import DecisionTreeClassifier

tree = DecisionTreeClassifier()
tree.fit(X_train, y_train)
```

Importando los Modelos

En el curso, ambos modelos se importan desde la biblioteca `scikit-learn`, la herramienta principal para Machine Learning en Python.

```
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
```

LogisticRegression

Clasificador lineal. Rápido y fácil de interpretar.

DecisionTreeClassifier

Clasificador basado en árbol. Visual e intuitivo.

📌 Ambos modelos forman parte de `sklearn`, que se instala con un único comando: `pip install scikit-learn`

Accuracy (Exactitud)

¿Qué mide?

El **porcentaje total de predicciones correctas** sobre el total de predicciones realizadas.

¿Cuándo usarla?

Es ideal cuando las clases del dataset están **balanceadas**, es decir, cuando hay una cantidad similar de ejemplos de cada categoría.



Si las clases están desbalanceadas, el Accuracy puede ser engañoso. Considera otras métricas.

Precision (Precisión)

¿Cuántas de las predicciones positivas fueron realmente correctas?

Interpretación

La Precisión mide qué tan **confiable** es el modelo cuando predice que algo es positivo. Un valor alto significa que cuando el modelo "dispara", casi siempre acierta.

Caso de uso en el curso

Detección de fraude bancario: es crucial evitar bloquear transacciones legítimas. Queremos que las alertas de fraude sean precisas.

Recall (Sensibilidad)

¿Cuántos de los positivos reales logró detectar el modelo?

Interpretación

El Recall mide la capacidad del modelo para **no perderse casos positivos reales**. Un valor alto significa que el modelo detecta la mayoría de los casos que existen.

Caso de uso en el curso

Diagnóstico médico: es fundamental no dejar pasar ninguna enfermedad. Preferimos falsos positivos antes que falsos negativos.

F1 Score

El **F1 Score** combina Precision y Recall en una única métrica. Es especialmente útil cuando **ambas métricas son igualmente importantes** y no queremos sacrificar una por la otra.

Representa el equilibrio óptimo entre detectar todos los positivos y hacerlo con precisión.



Matriz de Confusión

La Matriz de Confusión es una tabla que permite visualizar en detalle cómo se equivoca el modelo, desglosando los resultados en cuatro categorías.

✓ **Verdaderos Positivos**

Positivos predichos correctamente

✓ **Verdaderos Negativos**

Negativos predichos correctamente

✗ **Falsos Positivos**

Negativos clasificados como positivos

✗ **Falsos Negativos**

Positivos clasificados como negativos

ROC-AUC

¿Qué es?

Una métrica adicional que permite **comparar modelos** evaluando su desempeño a través de distintos umbrales de decisión.

¿Cómo se interpreta?

- Un valor de **1.0** indica un modelo perfecto
- Un valor de **0.5** indica que el modelo no es mejor que el azar
- Se usa para comparar y seleccionar el mejor modelo



El curso menciona esta métrica sin profundizar en sus detalles matemáticos.

MSE – Error Cuadrático Medio

¿Qué mide?

El promedio de los errores al cuadrado entre las predicciones y los valores reales.

Característica clave

Al elevar los errores al cuadrado, el **MSE penaliza más fuertemente los errores grandes**. Es sensible a valores atípicos (outliers). Cuanto menor sea el MSE, mejor es el modelo.

MAE — Error Absoluto Medio

¿Qué mide?

El promedio de las diferencias absolutas entre predicciones y valores reales.

Ventaja principal

El MAE es **más resistente frente a valores atípicos** que el MSE, ya que trata todos los errores de forma proporcional sin amplificarlos al cuadrado. Ideal cuando el dataset tiene outliers importantes.

R^2 – Coeficiente de Determinación

0.80

Ejemplo del curso

El modelo explica el **80 % de la variación** en los datos reales.

1.0

R^2 perfecto

El modelo explica el **100 %** de la variabilidad. Raro en la práctica.

0.0

Sin poder predictivo

El modelo no explica nada mejor que la media simple de los datos.

El R^2 indica qué porcentaje de la variabilidad de los datos puede ser explicado por el modelo. Un R^2 más cercano a 1 indica mejor ajuste.

Overfitting: El Sobreajuste

¿Qué es?

El modelo **aprende demasiado bien** los datos de entrenamiento, incluyendo el ruido y las particularidades específicas del conjunto.

Consecuencia

Funciona de forma excelente con datos de entrenamiento, pero **falla con datos nuevos**. El modelo memoriza en lugar de aprender a generalizar.

Técnicas para reducirlo

- Regularización
- Validación Cruzada



Caso 1: Detección de Fraude Bancario



El problema

Los bancos procesan **millones de transacciones** diariamente. Detectar fraude manualmente es imposible.

Antes

Sistemas basados en reglas
fijas, lentos y rígidos

Después

ML supervisado: más rápido,
preciso y adaptable

Caso 2: Recomendaciones en E-commerce

Las plataformas de comercio electrónico combinan múltiples fuentes de datos para construir un perfil completo del usuario y ofrecer recomendaciones relevantes en el momento exacto.



Historial de compras

¿Qué ha comprado el usuario anteriormente?




Historial de navegación

¿Qué productos ha visitado recientemente?



Datos demográficos

Perfil del usuario para personalizar aún más.



CASOS PRÁCTICOS

Caso 3: Vehículos Autónomos

1

Supervisado

Reconocimiento de objetos, señales y peatones

2


No Supervisado

Detección de nuevos escenarios no vistos

3

Refuerzo

Entrenamiento de decisiones de conducción



Bibliotecas Utilizadas en el Curso

Todas las implementaciones del curso se realizan con estas bibliotecas de Python. No se utilizan otras herramientas.

```
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score
from sklearn.metrics import precision_score
from sklearn.metrics import f1_score
import matplotlib.pyplot as plt
```

pandas

Manipulación de datos

scikit-learn


Modelos y métricas

matplotlib

Visualización

Flujo de Entrenamiento Completo

Este es el flujo detallado que sigue el curso, desde los datos crudos hasta la comparación final de modelos.



Cada paso del flujo tiene una función específica. Saltar alguno compromete la **validez** y **confiabilidad** de las conclusiones del proyecto.

Flujo de Evaluación de Modelos

Una vez entrenado el modelo, se realiza un proceso sistemático de evaluación para seleccionar el mejor.



- ❏ El curso destaca que **no existe una única métrica válida para todos los problemas**. La elección depende del contexto y del costo de cada tipo de error.

Flujo para Modelos de Regresión

Cuando el objetivo es predecir un valor numérico continuo (no una categoría), se utilizan métricas específicas de regresión.



Código Completo del Curso

Este es el ejemplo integrador que reúne todo el flujo: carga de datos, división, entrenamiento, predicción y evaluación comparativa de dos modelos.

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score
```

```
iris = load_iris()
X = iris.data
y = iris.target
```

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.30, random_state=42
)
```

```
log_reg = LogisticRegression()
tree = DecisionTreeClassifier()
```

```
log_reg.fit(X_train, y_train)
tree.fit(X_train, y_train)
```

```
pred_log = log_reg.predict(X_test)
pred_tree = tree.predict(X_test)
```

```
print("Accuracy Logistic:",
      accuracy_score(y_test, pred_log))
print("Accuracy Tree:",
      accuracy_score(y_test, pred_tree))
```


Ideas Clave del Curso

Estos son los conceptos esenciales que debes recordar al finalizar el curso.

1 ML aprende de los datos

No requiere reglas programadas manualmente. Los patrones emergen solos.

2 Tres tipos de aprendizaje

Supervisado, No Supervisado y por Refuerzo, cada uno con sus casos de uso.

3 Más datos = mejores modelos

En general, mayor cantidad de datos de calidad produce mejores predicciones.

4 Accuracy no siempre es suficiente

Precision, Recall, F1 y MSE/MAE/R² revelan distintos aspectos del desempeño.

5 Evita el sobreajuste

Un modelo que memoriza no generaliza. Regularización y validación cruzada ayudan.

Has recorrido todos los conceptos, modelos, métricas y casos prácticos cubiertos en los videos. Esta guía es fiel al contenido original: introductoria, visual y sin conceptos adicionales fuera del curso.

Conceptos

¿Qué es ML y cómo aprende

Modelos

Regresión Logística y Árbol de Decisión

Métricas

Clasificación y regresión

Código

Flujo completo con scikit-learn

✓ ¡Continúa practicando con el Iris Dataset y experimenta modificando los parámetros de los modelos!

